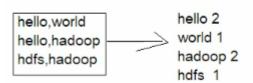
https://www.bilibili.com/video/BV1ek4y117Yq?p=74

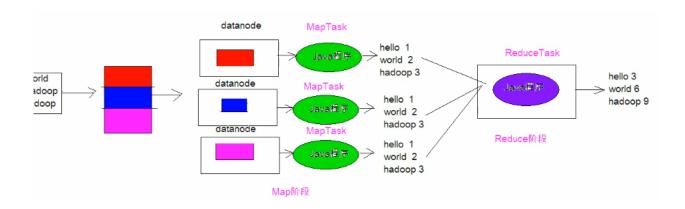
In [ ]:

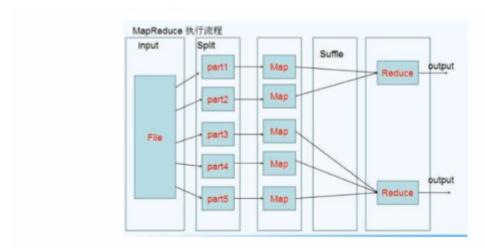
1

#### 1.设计流程

需求: a.txt 300M 统计文件中每个单词出现的次数







还有一个比较形象的语言解释MapReduce:

我们要数图书馆中的所有书。你**数1号书架**,我数2号书架。这就是"Map"。我们人越多,数书就更快。

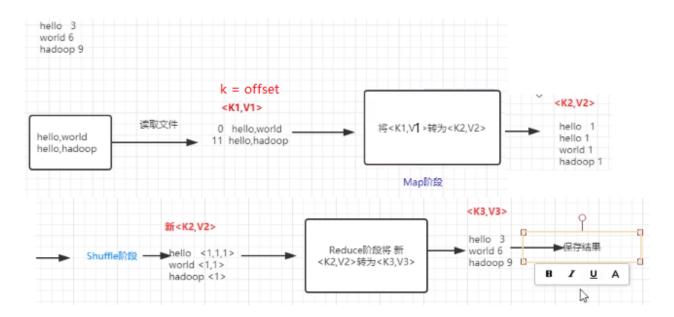
现在我们到一起,把所有人的统计数加在一起。这就是"Reduce"。

MapReduce是一个分布式运算程序的编程框架,核心功能是将用户编写的业务逻辑代码和自带默认组件整合成一个完整的分布式运算程序,并发运行在Hadoop集群上。

MapReduce设计并提供了统一的计算框架,为程序员隐藏了绝大多数系统层面的处理细节。 为程序员提供一个抽象和高层的编程接口和框架。程序员仅需要关心其应用层的具体计算问题,仅需编写少量的处理应用本身计算问题的程序代码。如何具体完成这个并行计算任务所相关的诸多系统层细节被隐藏起来,交给计算框架去处理:

Map和Reduce为程序员提供了一个清晰的操作接口抽象描述。MapReduce中定义了如下的Map和Reduce两个抽象的编程接口,由用户去编程实现.Map和Reduce,MapReduce处理的数据类型是<key,value>键值对。

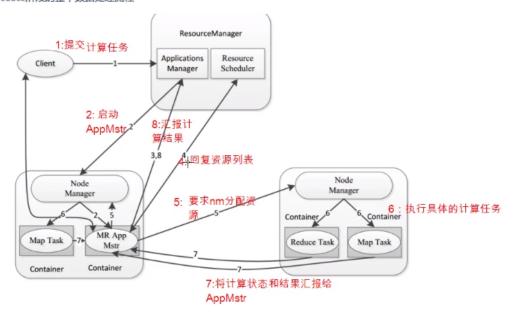
• Map: (k1; v1) → [|(k2; v2)] • Reduce: (k2; [v2]) → [(k3; v3)]



#### 了解mapreduce的计算框架

一个完整的mapreduke程序在分布式运行时有三类实例进程:

- 1. MRAppMaster 负责整个程序的过程调度及状态协调
- 2. MapTask 负责map阶段的整个数据处理流程
- 3. ReduceTask 负责reduce阶段的整个数据处理流程



#### 2.编程规范

MapReduce 的开发一共有八个步骤, 其中 Map 阶段分为 2 个步骤, Shuffle 阶段 4 个步骤, Reduce 阶段分为 2 个步骤

#### Map 阶段 2 个步骤

- 1. 设置 InputFormat 类, 将数据切分为 Key-Value (K1和V1) 对, 输入到第二步
- 2. 自定义 Map 逻辑,将第一步的结果转换成另外的 Key-Value (K2和V2) 对,输出结果

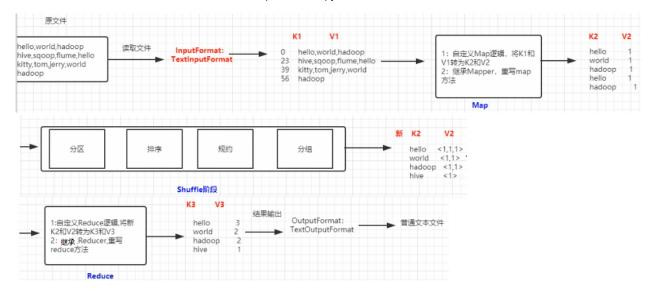
#### Shuffle 阶段 4 个步骤

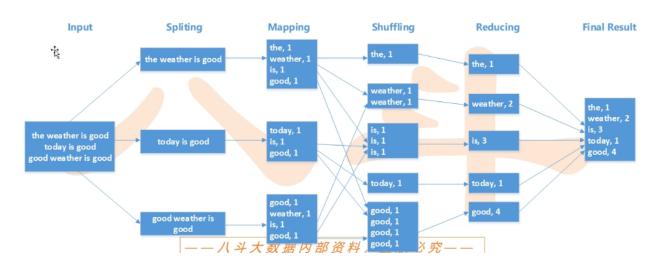
- 3. 对输出的 Key-Value 对进行分区
- 4. 对不同分区的数据按照相同的 Key 排序
- 5. (可选)对分组过的数据初步规约,降低数据的网络拷贝
- 6. 对数据进行分组,相同 Key 的 Value 放入一个集合中

#### Reduce 阶段 2 个步骤

- 7. 对多个 Map 任务的结果进行排序以及合并,编写 Reduce 函数实现自己的逻辑,对输入的 Key-Value 进行处理,转为新的 Key-Value (K3和V3)输出
- 8. 设置 OutputFormat 处理并保存 Reduce 输出的 Key-Value 数据

### 3.案例1---wordcount





### 4.mapreduce分区

### 分区概述

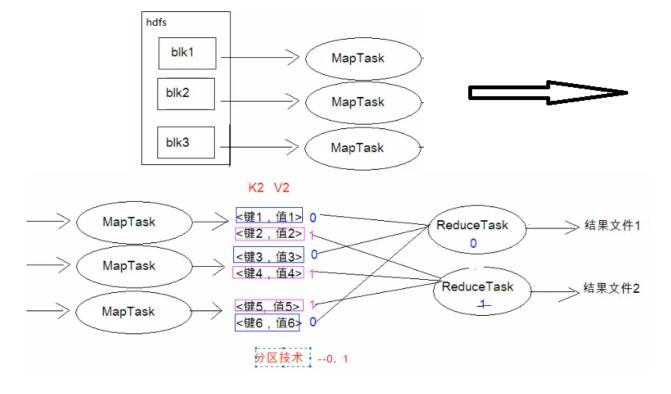
在 MapReduce 中,通过我们指定分区,会将同一个分区的数据发送到同一个 Reduce 当中进行处理

例如: 为了数据的统计, 可以把一批类似的数据发送到同一个 Reduce 当中, 在同一个 Reduce 当中统计相同类型的数据, 就可以实现类似的数据分区和统计等

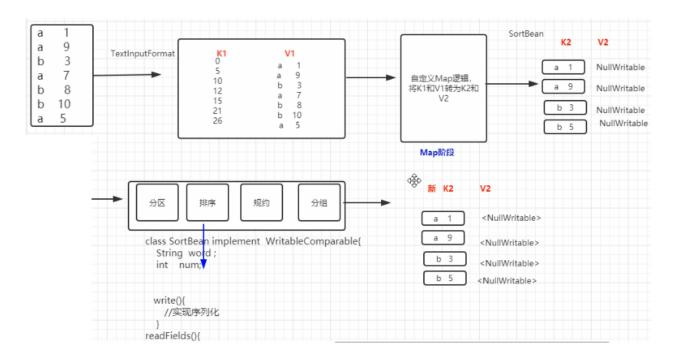
其实就是相同类型的数据,有共性的数据,送到一起去处理

Reduce 当中默认的分区只有一个





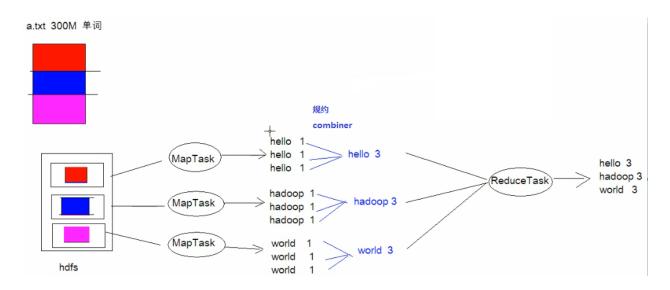
## 5.mapreduce的排序与序列化



# 6.规约combiner

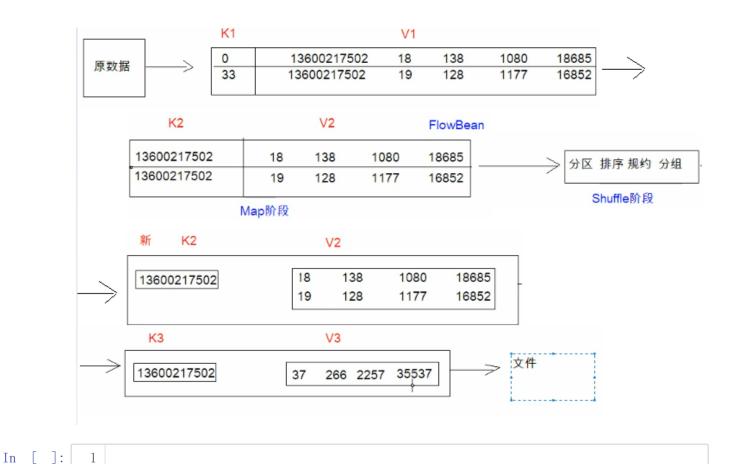
每一个 map 都可能会产生大量的本地输出,Combiner 的作用就是对 map 端的输出先做一次合并,以减少在 map 和 reduce 节点之间的数据传输量,以提高网络IO 性能,是 MapReduce 的一种优化手段之一

- combiner 是 MR 程序中 Mapper 和 Reducer 之外的一种组件
- combiner 组件的父类就是 Reducer
- combiner 和 reducer 的区别在于运行的位置
  - 。 Combiner 是在每一个 maptask 所在的节点运行
  - 。 Reducer 是接收全局所有 Mapper 的输出结果
- combiner 的意义就是对每一个 maptask 的输出进行局部汇总,以减小网络传输量



In [ ]: 1





###

2、mapreduce (复习)

- (1) 通常一个集群中,有这几个角色: master、slave、client
- (2) 数据副本——数据高可用、容灾
- (3) mapreduce——分而治之思想
- (4) 一个split和一个map是一对一的关系上
- (5) 开发java相当于开发函数,开发python等脚本,相当于规定好标准输入和输出
- (6) hadoop1.0 -> hadoop 2.0

hadoop1.0:

主: jobtracker、namenode 从: tasktracker、datanode

进程: worker

### hadoop 2.0

主: ResourceMgr (RM资源调度) 、ApplicationManager (AM任务调度)

从: NodeManager (NM)

进程:容器 (Container)

MapReduce和HDFS采用Java实现,默认提供Java编程接口 Streaming框架允许任何程序语言实现的程序在Hadoop MapReduce中 使用

Streaming方便已有程序向Hadoop平台移植

In	[	]:	1
In		]:	1
In	[	]:	1