https://www.bilibili.com/video/BV174411X7Pk?from=search&seid=16140933637673040363 (https://www.bilibili.com/video/BV174411X7Pk?from=search&seid=16140933637673040363)

https://www.bilibili.com/video/BV11A411L7CK?p=186 (https://www.bilibili.com/video/BV11A411L7CK?p=186)

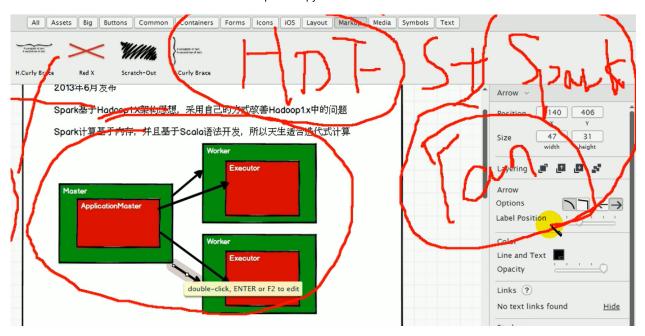
In	[]:	1	
In	[]:	1	

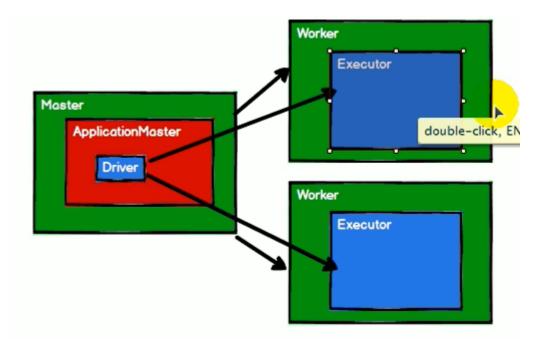
Spark 和 Hadoop 的根本差异是多个作业之间的数据通信问题: Spark 多个作业之间数据通信是基于内存,而 Hadoop 是基于磁盘。

经过上面的比较,我们可以看出在绝大多数的数据计算场景中,Spark 确实会比 MapReduce 更有优势。但是 Spark 是基于内存的,所以在实际的生产环境中,由于内存的限制,可能会由于内存资源不够导致 Job 执行失败,此时,MapReduce 其实是一个更好的选择,所以 Spark 并不能完全替代 MR。

- 存储的弹性:内存与磁盘的自动切换;
- 容错的弹性:数据丢失可以自动恢复;
- 计算的弹性: 计算出错重试机制:
- 分片的弹性:可根据需要重新分片。
- ▶ 分布式:数据存储在大数据集群不同节点上
- ➤ 数据集: RDD 封装了计算逻辑; 并不保存数据
- ▶ 数据抽象: RDD 是一个抽象类,需要子类具体实现
- ➤ 不可变: RDD 封装了计算逻辑,是不可以改变的,想要改变,只能产生新的 RDD,在新的 RDD 里面封装计算逻辑
- > 可分区、并行计算

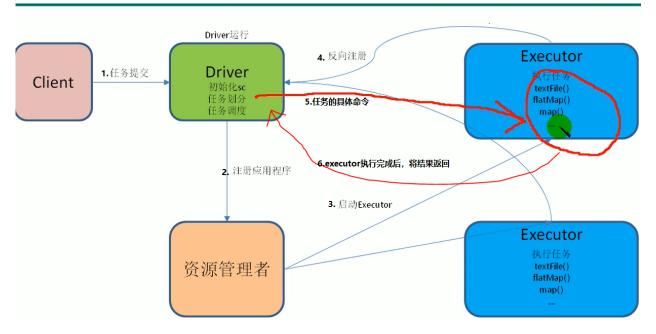
In	[]:	٦. [1	
		۱ ۰ ۱	1	

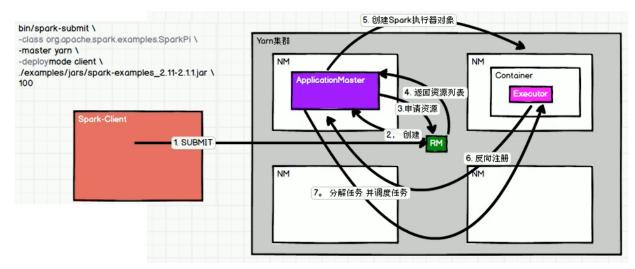




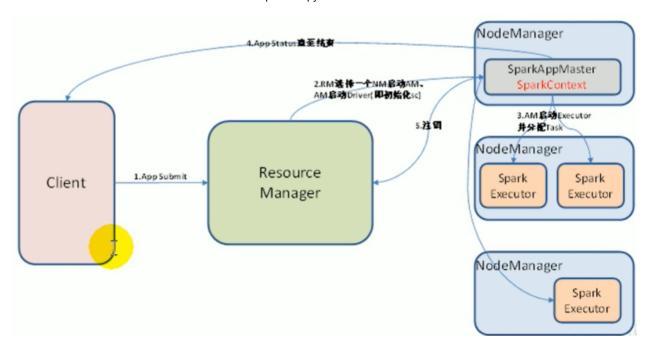
〉Spark通用运行简易流程



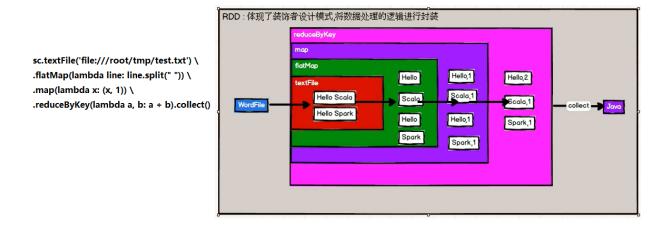


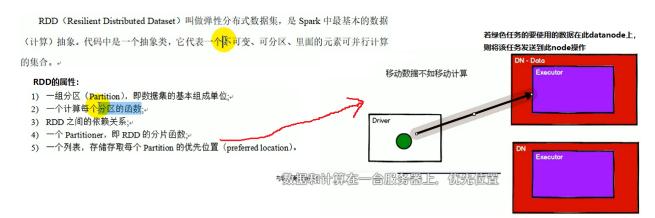


4.返回资源列表--返回可用的NM, applicationmaster所在的NM就不是可用的NM



RDD (Resilient Distributed Dataset) 叫做<mark>弹性</mark>分布式数据集,是 Spark 中最基本的数据抽象。代码中是一个抽象类,它代表一个不可变、可分区、里面的元素可并行计算的集合。





RDD 表示只读的分区的数据集,对 RDD 进行改动,只能通过 RDD 的转换操作,由一个 RDD 得到一个新的 RDD,新的 RDD 包含了从其他 RDD 衍生所必需的信息。RDDs 之间存在依赖,RDD 的执行是按照血缘关系延时计算的。如果血缘关系较长,可以通过持久化 RDD 来切断血缘关系。4

算子:

由一个 RDD 转换到另一个 RDD,可以通过丰富的操作算子实现,不再像 MapReduce 那样只能写 map 和 reduce 了

算子:从认知心理学角度,解决问题其实是将。问题的初始状态,通过一系列的操作 (Operate)(算子)对问题的状态进行转换,然后达到完成(解决)状态 Spark中的所有的RDD方法都称之为算子,但是分为2大类:转换算子 & 行动算子 转换结构

依赖关系:

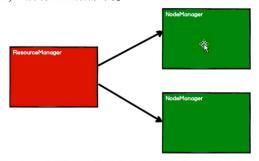
RDDs 通过操作算子进行转换,转换得到的新 RDD 包含了从其他 RDDs 衍生所必需的信息,RDDs 之间维护着这种血缘关系,也称之为依赖。 依赖包括两种,一种是窄依赖,RDDs 之间分区是一一对应的,另一种是宽依赖,下游 RDD 的每个分区与上游

为防止血缘关系中断,需要将血缘关系缓存起来。

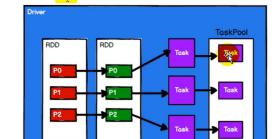
RDD(也称之为父 RDD)的每个分区都有关,是多对多的关系。

In []: 1

1) 启动 Yarn 集群环境

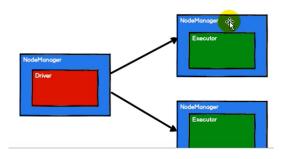


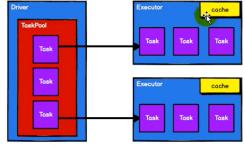
2) Spark 通过申请资源创建调度节点和计算节点



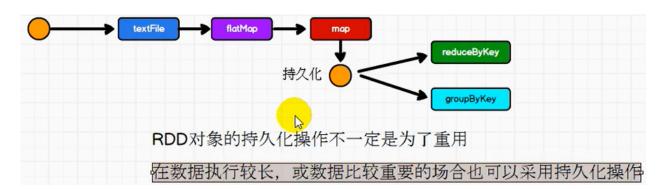
4) 调度节点将任务根据计算节点状态发送到对应的计算节点进行计算

Spark 框架根据需求将计算逻辑根据分区划分成不同的任务





In []: 1



```
In [ ]: 1
```

```
// cache:将数据临时存储在内存中进行数据重用
// persist:将数据临时存储在磁盘文件中进行数据重用
// 涉及到磁盘IO,性能较低,但是数据安全
// 如果作业执行完毕,临时保存的数据文件就会丢失
// checkpoint:将数据长久地保存在磁盘文件中进行数据重用
// 涉及到磁盘IO,性能较低,但是数据安全
// 为了保证数据安全,所以一般情况下,会独立执行作业
为了能够提高效率,一般情况下,是需要和cache联合使用
```