

实时推荐

网站初期，在没有排序模型情况下，可直接根据商品的相似度，找出用户当前正在发生行为的商品的相似商品进行推荐(在线召回)

In [87]:

```
1 import os
2 # 配置pyspark和spark driver运行时 使用的python解释器
3 JAVA_HOME = '/root/bigdata/jdk'
4 PYSPARK_PYTHON = '/miniconda2/envs/py365/bin/python'
5 # 当存在多个版本时，不指定很可能会导致出错
6 os.environ['PYSPARK_PYTHON'] = PYSPARK_PYTHON
7 os.environ['PYSPARK_DRIVER_PYTHON'] = PYSPARK_PYTHON
8 os.environ['JAVA_HOME'] = JAVA_HOME
9 # 注意，如果是使用jupyter或ipython中，利用spark streaming链接kafka的话，必须加上下面语
10 # 同时注意：spark version>2.2.2的话，pyspark中的kafka对应模块已被遗弃，因此这里暂时只
11 os.environ["PYSPARK_SUBMIT_ARGS"] = "--packages org.apache.spark:spark-streaming-kafka
12 # 配置spark信息
13 from pyspark import SparkConf
14 import pyspark
15
16 SPARK_APP_NAME = "meiduo_logs"
17 SPARK_URL = "spark://192.168.58.100:7077"
18
19 conf = SparkConf() # 创建spark config对象
20 config = (
21     ("spark.app.name", SPARK_APP_NAME), # 设置启动的spark的app名称，没有提供，将随
22     ("spark.executor.memory", "2g"), # 设置该app启动时占用的内存用量，默认1g，指一
23     ("spark.master", SPARK_URL), # spark master的地址
24     ("spark.executor.cores", "2"), # 设置spark executor使用的CPU核心数，指一台虚拟
25     # ("hive.metastore.uris", "thrift://localhost:9083"), # 配置hive元数据的访问，
26
27     # 以下三项配置，可以控制执行器数量
28     # ("spark.dynamicAllocation.enabled", True),
29     # ("spark.dynamicAllocation.initialExecutors", 1), # 1个执行器
30     # ("spark.shuffle.service.enabled", True)
31     # ('spark.sql.pivotMaxValues', '99999'), # 当需要pivot DF，且值很多时，需要修改，默
32 )
33 # 查看更详细配置及说明：https://spark.apache.org/docs/latest/configuration.html
34
35 conf.setAll(config)
36
37 # 利用config对象，创建spark session
38 sc = pyspark.SparkContext(master=SPARK_URL, conf=conf)
```

```
In [88]: 1 # 注意：初次安装并运行时，由于使用了kafka，所以会自动下载一系列的依赖jar包，会耗费一定
2
3 from pyspark.streaming.kafka import KafkaUtils
4 from pyspark.streaming import StreamingContext
5
6 # 第2个参数表示 程序运行间隔时间
7 ssc = StreamingContext(sc, 0.5)
8
9 kafkaParams = {"metadata.broker.list": "192.168.58.100:9092"}
10 dstream = KafkaUtils.createDirectStream(ssc, ["meiduo_click_trace"], kafkaParams)
```

注意row[1]是什么意思？

以下段代码为例：

```
from pyspark.streaming.kafka import KafkaUtils
from pyspark.streaming import StreamingContext

# 第2个参数表示 程序运行间隔时间
ssc = StreamingContext(sc, 0.5)

kafkaParams = {"metadata.broker.list": "192.168.58.100:9092"}
dstream = KafkaUtils.createDirectStream(ssc, ["meiduo_click_trace"], kafkaParams)
def preprocessing(row):
    return row[1]
def foreachRDD(rdd):
    print("foreachRDD", rdd.collect())
dstream.map(preprocessing).foreachRDD(foreachRDD)

ssc.start()
```

无论使用row还是row[1]，结果是一样的

```

In [89]: 1 import re
2 def preprocessing(row):
3     match = re.search("\
4 exposure_timesteamp<(P<exposure_timesteamp>.*?)> \
5 exposure_loc<(P<exposure_loc>.*?)> \
6 timesteamp<(P<timesteamp>.*?)> \
7 behavior<(P<behavior>.*?)> \
8 uid<(P<uid>.*?)> \
9 sku_id<(P<sku_id>.*?)> \
10 cate_id<(P<cate_id>.*?)> \
11 stay_time<(P<stay_time>.*?)>", row[1])
12
13     result = []
14     if match:
15         result.append(("exposure_timesteamp", match.group("exposure_timesteamp")))
16         result.append(("exposure_loc", match.group("exposure_loc")))
17         result.append(("timesteamp", match.group("timesteamp")))
18         result.append(("behavior", match.group("behavior")))
19         result.append(("uid", match.group("uid")))
20         result.append(("sku_id", match.group("sku_id")))
21         result.append(("cate_id", match.group("cate_id")))
22         result.append(("stay_time", match.group("stay_time")))
23     return result #得到用户实时点击结果
24
25 import redis
26 client0 = redis.StrictRedis(db=0) # 此前redis 0号库中已经存储了每个商品的TOP-N个相
27 client1 = redis.StrictRedis(db=1)
28
29 # 根据实时点击的日志->取出uid和sku_id->根据这两个id, 去redis中找到对应的相似物品
30 def foreachRDD(rdd):
31     # 网站初期, 在没有排序模型情况下, 可直接根据商品的相似度, 找出用户当前正在发生行为
32     for data in rdd.collect():
33         # 你忘了吗? python 字典的生成
34         # test1=[('ni',1), ('hao',2), ('ma',3)]
35         # test2=dict(test1)
36         # test2
37         # {'ni': 1, 'hao': 2, 'ma': 3}
38         data = dict(data)
39         sku_id = data.get("sku_id")
40         uid = data.get("uid")
41
42         sim_skus = client0.zrevrange(sku_id, 0,4) # 取出最相似的前5个
43         client1.sadd(uid, *sim_skus) # 放入用户的召回集中

```

```

In [90]: 1 dstream.map(preprocessing).foreachRDD(foreachRDD)

```

```

In [91]: 1 ssc.start()

```

```

In [94]: 1 # 输入一条点击流日志，比如用户1浏览(pv)了 商品sku_id=19, 返回5个与sku_id最相似的商品
2 import logging#log: 记录
3 import time
4
5 def get_logger(logger_name, path, level):
6
7     # 创建logger
8     logger = logging.getLogger(logger_name)
9     # level: OFF、FATAL、ERROR、WARN、INFO、DEBUG、ALL或者自己定义的级别
10    logger.setLevel(level)
11
12    # 创建formatter
13    # %(asctime)s: 打印日志的时间
14    # %(message)s: 打印日志信息
15    fmt = '%(asctime)s: %(message)s'
16    datefmt = '%Y/%m/%d %H:%M:%S'
17    formatter = logging.Formatter(fmt, datefmt)
18
19    # 创建handler
20    # FileHandler: writes formatted logging records to disk files
21    handler = logging.FileHandler(path)
22    handler.setLevel(level)
23
24    # 添加handler和formatter 到 logger
25    handler.setFormatter(formatter)
26    logger.addHandler(handler)
27
28    return logger
29
30 click_trace_logger = get_logger('click_trace', '/root/workspace/3.rs_project/project2/1
31                                logging.DEBUG)
32
33 # 点击流日志
34 exposure_timestamp = time.time()
35 exposure_loc = 'detail'
36 timestamp = time.time()
37 behavior = 'pv' # pv|浏览 cart|加入购物车 fav|喜爱 buy|购买
38 uid = 4
39 sku_id = 26
40 cate_id = 1
41 stay_time = 60
42 # # 假设某点击流日志记录格式如下:
43 click_trace_logger.info("exposure_timestamp<%d> exposure_loc<%s> timestamp<%d> behav
44                        %(exposure_timestamp, exposure_loc, timestamp, behavior, uid
45

```

```

In [100]: 1 # 你忘了吗? python 字典的生成
2 # test1=[('ni', 1), ('hao', 2), ('ma', 3)]
3 # test2=dict(test1)
4 # test2
5 # {'ni': 1, 'hao': 2, 'ma': 3}

```

```

In [95]: 1 ssc.stop()

```

但当网站运行一段时间后，已经收集了大量的用户行为数据以后，那么在离线处理中，就可以训练出相关排序模型(点击率预测、跳出率预测、转化率预测)。由于离线推荐主要以T+1形式推荐，因此在线推荐就还需要对用户今日的行为进行统计分析，得出用户今日的实时兴趣作为用户的实时画像，**供排序模型使用**

今天之前是一个 T单位的数据,新加一天就是 (T + 1) 单位的数据。